

## 統計解析手法 時系列データの統計解析

2015/06/25

中西航

nakanishi [at] civil.t.u-tokyo.ac.jp

### 時系列データとはなにか？

3

- 時系列データ：時間の推移と共に観測されるデータ
- しかし、ほとんどのデータは時間の推移と共に観測されるのではないか？
- 通常は観測される順序に意味があるもののことを時系列データという
- 順序に意味があるとはどういうことか？

A氏の身長 (6/24 PM 1:00で 172.1cm)

〇意味がある → A氏の身長が時間変化を伴っている

〇意味がない → 20代の男性の平均身長を //

- (工学系や経済学系における) 代表的な書籍
  - 北川源四郎 「時系列解析入門」 岩波書店
  - 沖本竜義 「経済・フィナンスデータの計量時系列分析」 朝倉書店
  - 廣松毅・浪花貞夫・高岡慎 「経済時系列分析」 多賀出版
- 厚い本が1冊書けるようなトピック
- 学内にも時系列だけを1学期間扱う講義あり
- 数学的・情報学的な研究もいまだ盛ん
- 今日は本当の入門だけを紹介

### 基本統計量

5

- 時間は離散化して考える
- データの記述方法



- 平均 mean

$$\mu = E(y_t)$$

←  $t = t_k$  での分布を見る[0, ∞] での  $y_t$  の平均を見るわけではない

- 分散 variance

$$V(y_t) = E(y_t - \mu_t)^2$$

- 標準偏差(≡ボラティリティ) standard deviation

$$\sqrt{V(y_t)}$$



- 自己共分散 autocovariance

同一の時系列における異時点間の共分散

- 1次の自己共分散

$$\gamma_t = \text{Cov}(y_t, y_{t-1}) = E[(y_t - \mu_t)(y_{t-1} - \mu_{t-1})]$$

- k次の自己共分散

$$\gamma_{kt} = \text{Cov}(y_t, y_{t-k})$$

- 自己共分散関数

$\gamma_{kt}$  を  $k$  の関数として見たもの

## 確率過程 Stochastic Process

- 時系列データはふつう1度しか観測できない

- 無数の観測(試行)が可能であるという前提で平均や分散を定義することはいできない

- 2015年1月1日の気温から、2015年1月1日の気温の期待値や分散を求めることは統計的に不可能

- そこで、一連の観測を、確率変数の列からの実現値とみなす：確率過程 stochastic process

$$\{y_t\}_{t=-\infty}^{\infty} \quad \text{これは実現値の連続}$$

$$\{y_t\}_{t=1}^T = y_1, y_2, \dots, y_T$$

- 自己相関(係数) autocorrelation coefficient


統計学的な相関係数と表裏は変化する。

- 自己相関関数  $\rho_k$  の関数

$$\rho_{kt} = \text{Corr}(y_t, y_{t-k}) = \frac{\text{Cov}(y_t, y_{t-k})}{\sqrt{V(y_t)}\sqrt{V(y_{t-k})}} = \frac{\gamma_{kt}}{\sqrt{\gamma_{0t} \gamma_{0t-k}}}$$

$$\rho_{0t} = 1, |\rho_{kt}| \leq 1$$

- コレログラム



自己共分散と表裏

## 定常性 Stationarity

- 確率過程に対して時間不変なものを想定する
- 何を不変とするかによって「弱定常性」と「強定常性」の2つがある

- 弱定常性：以下の(1)(2)が成り立つ場合

- (1) 平均は時間不変  $E(y_t) = \mu$

- (2) 自己共分散は時間差のみに依存

$$\text{Cov}(y_t, y_{t-k}) = \gamma_k \quad \text{ここで } t=1, 2, 3, \dots$$

- このとき、自己相関も時間差のみに依存

$$\text{Corr}(y_t, y_{t-k}) = \frac{\gamma_k}{\gamma_0} = \rho_k$$



- 確率過程に対して時間不変なものを想定する
- 何を不変とするかによって「弱定常性」と「強定常性」の2つがある

- 強定常性：以下が成り立つ場合

- 同時分布が任意の時刻の組に対して同一

$$(y_t, y_{t+1}, \dots, y_{t+k})^T \text{ の同時分布が } t, k \text{ に依らず同一}$$

- 現実的な問題

- 定常を仮定すると時系列解析が行いやすくなるので、いろいろな工夫をして定常を仮定することが多い
- データが(本当に)定常かどうかを判定することは難しい

## 【参考】工学部の数学では何を行うのか

13

- 理論(モデル、解法)の勉強

- モデルやそれが成立する条件、その数学的な解き方は数学者が示してくれている(と考える)

- 実践：現実の問題に対してどう適用するか

- データの取得
  - どういうデータを集めるべきか
- モデルの作成と決定
  - どういうモデルを当てはめるべきか、分析したいことはどういうモデルの成立条件を満たしているか
- パラメータの推定と決定
  - 計算可能性を満たしているか
- 結果の解釈・将来の予測
  - 妥当な結果か、新たな発見はあるか、役に立つか

## iid系列・ホワイトノイズ

- 各時点のデータが独立に同一の分布に従う系列：iid系列
  - 期待値0のiid系列はモデルの擾乱項(確率的変動を表現する部分：≡誤差項)として扱える

$$y_t \sim iid(\mu, \sigma^2)$$

- 独立・同一分布の仮定を少し緩める→ホワイトノイズ

$$E(\varepsilon_t) = 0$$

$$Y_k = (\varepsilon_t, \varepsilon_{t+1}) = \begin{cases} \sigma^2 & (k=0) \\ 0 & (k \neq 0) \end{cases}$$

$$\varepsilon_t \sim wn(\sigma^2)$$

平均0の乱数

## 時系列解析の代表的モデル

14

- 結局のところ自己相関のモデル化ができればよい

- MA過程 (Moving Average: 移動平均)
- AR過程 (Auto Regression: 自己回帰)
- ARMA過程 (自己回帰移動平均)

- 今から説明すること

- モデル自体の説明
- パラメータ推定の方法
- データを得たときのモデル化の方法
- 複数のモデルが得られたときに良いものを選ぶ方法
- 推定されたモデルを用いた予測の方法



- 時系列データをホワイトノイズの線形和で表したもの

- 例：1次のMA過程(MA(1)と表記)

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} = MA(1)$$

$$y_{t-1} = \mu + \varepsilon_{t-1} + \theta_1 \varepsilon_{t-2}$$

- 自己相関が発生する仕組み

(指定可能)  
 $\varepsilon_t$  と  $\theta_1 \varepsilon_{t-1}$  が決まる  
 $y_t$  も決まる

- ホワイトノイズ  $\varepsilon_t$  の値が決まると  $y_t$  の値も決まる

## MA(1)の統計量

- 期待値

$$E(y_t) = E(\mu + \varepsilon_t + \theta_1 \varepsilon_{t-1}) = \mu$$

$E(\varepsilon_t) = 0$   
 定数

- 分散

$$\begin{aligned} \sigma_{y_t}^2 &= V(y_t) = V(\mu + \varepsilon_t + \theta_1 \varepsilon_{t-1}) = V(\varepsilon_t) + \theta_1^2 V(\varepsilon_{t-1}) + 2\theta_1 \text{Cov}(\varepsilon_t, \varepsilon_{t-1}) \\ &= (1 + \theta_1^2) \sigma^2 \geq \sigma^2 \end{aligned}$$

- 共分散

$$\begin{aligned} \gamma_k &= \text{Cov}(y_t, y_{t-k}) = \text{Cov}(\varepsilon_t, \varepsilon_{t-k}) + \text{Cov}(\varepsilon_t, \theta_1 \varepsilon_{t-k-1}) + \text{Cov}(\theta_1 \varepsilon_{t-1}, \varepsilon_{t-k}) + \text{Cov}(\theta_1 \varepsilon_{t-1}, \theta_1 \varepsilon_{t-k-1}) \\ &= 0, \sigma^2 \end{aligned}$$

- 1次の自己相関

$$\rho_1 = \frac{\theta_1}{1 + \theta_1^2} \quad (|\rho_1| \leq \frac{1}{2})$$

- 高次の自己相関

$$k \geq 2 \text{ とき } \rho_k = 0$$

- MA(1)

$$\theta_1 = 0.8$$

滑らか

$$\theta_1 = 0.5$$

ギザギザ




$$\theta_1 = 2.7$$

- MA(2)

$$\theta_1 = 0.8, \theta_2 = 0.5$$

$$\theta_1 = 0.8, \theta_2 = -0.5$$

$$\theta_1 = 2.7, \theta_2 = -0.5$$



## MA(q)過程

- 式

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}$$

- 期待値

$$E(y_t) = \mu$$

- 分散

$$\sigma^2(y_t) = \sigma^2 = (1 + \theta_1^2 + \theta_2^2 + \dots + \theta_q^2) \sigma^2$$

- 共分散

$$\gamma_k = \begin{cases} (1 + \theta_1 \theta_{k-1} + \dots + \theta_{q-k} \theta_q) \sigma^2 & (1 \leq k \leq q) \\ 0 & (k > q) \end{cases}$$

- 自己相関

$$\rho_k = \begin{cases} \frac{\theta_k + \theta_1 \theta_{k-1} + \dots + \theta_{q-k} \theta_q}{1 + \theta_1^2 + \dots + \theta_q^2} & (1 \leq k \leq q) \\ 0 & (k > q) \end{cases}$$

- パラメータの値によらず常に定常




- 例：パラメータの値とコログラム

MA(1)



MA(2)




問題点

- 自己相関が長い期間ある場合にはパラメータが膨大に必要
- パラメータがホワイトノイズにかかっているので、得られたモデルや適用結果の意味解釈が難しい
- 同一の期待値と自己相関を持つMA(q)過程が複数存在しうる


例

AR(1)


- $c=0, \phi_1=0.8$



- $c=0, \phi_1=-0.5$






- $c=2, \phi_1=0.7$



AR(2)

- $c=0, \phi_1=0.8, \phi_2=0.1$
- $c=0, \phi_1=-0.6, \phi_2=0.3$
- $c=2, \phi_1=0.2, \phi_2=0.7$



AR過程

- 過程が自身の過去に回帰された形で表現されるもの

- 例：1次のAR過程(AR(1)と表記)

$$y_t = c + \phi_1 y_{t-1} + \varepsilon_t$$

$$y_{t-1} = c + \phi_1 y_{t-2} + \varepsilon_{t-1}$$

- 自己相関が発生する仕組み

MAで同じ考え

- ホワイトノイズ $\varepsilon_t$ の値が決まると $y_t$ の値も決まる
- MA過程と異なり、

- AR過程は常に定常とは限らない

- AR(1)が定常になるのは $|\phi_1| < 1$ のとき

- 期待値は定数項とは一致しない
- 初期値を決定する必要がある

AR(1)過程の統計量

- 期待値

$$E(y_t) = E(c + \phi_1 y_{t-1} + \varepsilon_t) = c + \phi_1 E(y_{t-1})$$

$$\Leftrightarrow \mu = c + \phi_1 \mu \Rightarrow \mu = \frac{c}{1 - \phi_1}$$

- 分散

$$\begin{aligned} \gamma_0 &= V(y_t) = V(c + \phi_1 y_{t-1} + \varepsilon_t) = \phi_1^2 V(y_{t-1}) + V(\varepsilon_t) + 2\phi_1 \underbrace{Cov(y_{t-1}, \varepsilon_t)}_{=0} \\ &= \phi_1^2 \gamma_0 + \sigma^2 \end{aligned}$$

$$\therefore \gamma_0 = \frac{\sigma^2}{1 - \phi_1^2}$$

- 共分散

$$\begin{aligned} \gamma_t &= \text{Cov}(y_t, y_{t-k}) = \text{Cov}(y_t, y_{t-k}) = \text{Cov}(\phi_1 y_{t-1} + \varepsilon_t, y_{t-k}) \\ &= \text{Cov}(\phi_1 y_{t-1}, y_{t-k}) = \phi_1 \gamma_{t-1} \Leftrightarrow \gamma_t = \phi_1 \gamma_{t-1} \end{aligned}$$

- 自己相関

- ユール・ウオーカー方程式 Yule-Walker equation

$$\gamma_k = \phi_1 \gamma_{k-1}$$

自己相関の評価式

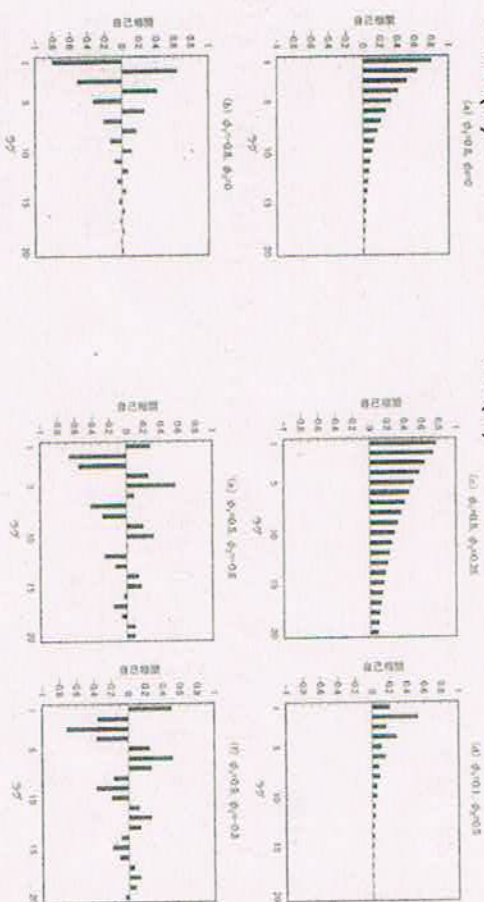
## AR(p)過程

25

- 例：パラメータの値とコログラム

- AR(1)

AR(2)



## AR(p)過程[定常な場合]

24

- 式  $y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t$
- 期待値  $E(y_t) = \frac{c}{1 - \phi_1 - \dots - \phi_p}$
- 分散  $\text{Var}(y_t) = \gamma_0 = \frac{\sigma^2}{1 - \phi_1^2 - \dots - \phi_p^2}$
- 共分散と自己相関

$$\gamma_k = \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2} + \dots + \phi_p \gamma_{k-p} \quad (k \geq 1)$$

$$\gamma_k = \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2} + \dots + \phi_p \gamma_{k-p}$$

- 自己相関は指数的に減少する

## AR過程の定常性

26

- AR(2)過程のユール・ウオーカー方程式

$$\gamma_k = \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2}$$

$$k=1 \text{ かつ } \gamma_1 = \phi_1 \gamma_0 + \phi_2 \gamma_{-1} \Leftrightarrow \gamma_1 = \frac{\phi_1}{1 - \phi_2}$$

p/A 定常性

$$k=2 \text{ かつ } \gamma_2 = \phi_1 \gamma_1 + \phi_2 \gamma_0 = \frac{\phi_1^2 + \phi_2 - \phi_2^3}{1 - \phi_2}$$

- AR(p)過程のユール・ウオーカー方程式[省略]

- $\phi_1$  から  $\phi_{p-1}$  までは連立方程式を解くと求まる
- $\phi_p$  以降は逐次求まる

- AR特性方程式と定常性

$$1 - \phi_1 z - \phi_2 z^2 = 0 \text{ の根 } \lambda_1, \lambda_2 \text{ を求める}$$

$$\gamma_k = \frac{(1 - \lambda_1^2) \lambda_1^{k-1} - (1 - \lambda_2^2) \lambda_2^{k-1}}{(\lambda_1 - \lambda_2)(1 + \lambda_1 \lambda_2)}$$

根が1より小さいと定常性



- p次のAR過程とq次のMA過程を組み合わせたもの
- ARMA過程(ARMA(p, q)と表記)
 
$$y_t = c + \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$
- 平均  $E(y_t) = \frac{c}{1 - \phi_1 - \dots - \phi_p}$  ← ARと同じ
- q+1次以降の自己共分散・自己相関
 
$$\gamma_k = \phi_1 \gamma_{k-1} + \dots + \phi_p \gamma_{k-p}$$

$$\rho_k = \phi_1 \rho_{k-1} + \dots + \phi_p \rho_{k-p}$$

εは白雑音  
εは白雑音
- q次まではMAの性質があるため表現は難しい
- 自己相関は指数的に減衰

## ARMA過程の定常性


29

- ARMA過程のAR部分が定常⇒そのARMA過程は定常
- いくつかの重要なこと
- AR過程が定常である⇔AR過程がMA(∞)過程に書き直せる
  - 従って、定常なARMA過程はMA(∞)過程に書き直せる
- MA過程がAR(∞)過程に書き直せるとき、反転可能とよぶ
- 【復習】MA過程は定常だが、同一の期待値と自己相関を持つ異なるMA過程が存在する場合がある
  - 反転可能なMA過程を選択することが望ましい
- MA特性方程式と反転可能な条件
 
$$1 + \theta_1 z + \dots + \theta_q z^q = 0$$

MA特性方程式  
反転可能: 解が絶対値が1より大きくなることはない
- これを満たすとき、ARMA過程全体も反転可能

## 例

- ARMA(1, 1), c=0
  - $\phi_1=0.8, \theta_1=0.4$ 
 $\phi_1=0.8, \theta_1=-0.4$ 
 $\phi_1=-0.8, \theta_1=-0.4$
- ARMA(2, 2), c=0
  - $\phi_1=0.2, \phi_2=0.1, \theta_1=0.8, \theta_2=-0.3$



## ARMAモデルの推定[最小二乗法]

30

- AR(1)を例に、誤差項はiid正規分布に従うと仮定
 
$$y_t = c + \phi_1 y_{t-1} + \varepsilon_t, \varepsilon_t \sim \text{iid } N(0, \sigma^2)$$

$$E = \sum_{t=1}^T \varepsilon_t^2 = \sum_{t=1}^T (y_t - \hat{c} - \phi_1 y_{t-1})^2 \rightarrow \min$$
- 正規方程式
 
$$\frac{\partial E}{\partial \phi_1} = \dots = 0$$

極小を探して
- 自己共分散する、例えばy\_tとy\_{t-1}
 
$$\hat{c} = \bar{y}_t - \phi_1 \bar{y}_{t-1}$$

$$\hat{\phi}_1 = \frac{\sum_{t=1}^T (y_t - \bar{y}_t)(y_{t-1} - \bar{y}_{t-1})}{\sum_{t=1}^T (y_{t-1} - \bar{y}_{t-1})^2}$$

$$y_t = \bar{y}_t + z_t$$

$$\bar{y}_t = \frac{1}{T} \sum_{t=1}^T y_t$$



- AR(1)を例に、誤差項はiid正規分布に従うと仮定

- AR(p)過程の最小二乗推定量は以下の性質を持つ

- 一致推定量である
- 基準化すると漸近的に正規分布に従う
- 誤差項がiid正規分布に従うとき、一致推定量のなかで、漸近的に最小の分散共分散行列を持つ
- しかし、BLUEではない(不偏ではない)
- ARMAは最小二乗法では推定できない

## ARMAモデルの選択

33

- ARMA(p, q)のpとqを決めないとパラメトリックにモデルが記述できないので、推定もできない
- 自己相関の様子をみながら、モデルの候補を列挙する
- 人間が見て判断するand/orコンピュータに任せる
- あくまでも参考になる情報としては以下:
  - MA(q)は自己相関関数が最大となるqを選ぶとよいかも
  - AR(p)は偏自己相関関数が最大となるpを選ぶとよいかも
- 必ずいくつかの候補で推定を試すこと!
- 偏自己相関 Partial autocorrelation
- $y_t$ と $y_{t-k}$ の間だけの相関
- 具体的には次式の解 $\phi_{kk}$ のこと

$$\begin{pmatrix} 1 & \rho_1 & \dots & \rho_{p-1} \\ \rho_1 & 1 & \dots & \rho_{p-2} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p-1} & \rho_{p-2} & \dots & 1 \end{pmatrix} \begin{pmatrix} \phi_{11} \\ \phi_{12} \\ \vdots \\ \phi_{1p} \end{pmatrix} = \begin{pmatrix} \rho_1 \\ \rho_2 \\ \vdots \\ \rho_p \end{pmatrix}$$

y<sub>t-1</sub>, y<sub>t-2</sub>, ..., y<sub>t-(k-1)</sub> は y<sub>t</sub> と...

## ARMAモデルの推定[最尤法]

32

- AR(1)を例に、誤差項はiid正規分布に従うと仮定
- 未知パラメータ(c,  $\phi_1$ ,  $\sigma^2$ )
- 同時密度  $f(y_T, y_{T-1}, \dots, y_1 | c, \phi_1, \sigma^2) = \prod_{t=1}^T f(y_t | y_{t-1}; c, \phi_1, \sigma^2) \rightarrow \max$ .

AR(1)だから

- ここで  $f(y_t | y_{t-1}) \sim N(c + \phi_1 y_{t-1}, \sigma^2)$  を用いて計算すると

$$\hat{c} = \bar{y}_T - \hat{\phi}_1 \bar{y}_{T-1}, \quad \hat{\phi}_1 = \frac{\sum_{t=1}^T (y_t - \bar{y}_T)(y_{t-1} - \bar{y}_{T-1})}{\sum_{t=1}^T (y_{t-1} - \bar{y}_{T-1})^2}, \quad \hat{\sigma}^2 = \frac{1}{T} \sum_{t=1}^T (y_t - \hat{c} - \hat{\phi}_1 y_{t-1})^2$$

ただし、

$$\bar{y}_T = \frac{1}{T} \sum_{t=1}^T y_t$$

答え = 32 (AR(1)に代入して)

- AR(p)過程の最尤推定量は以下の性質を持つ
- 一致推定量である
- 基準化すると漸近的に正規分布に従う
- 一致推定量のなかで漸近的に最小の分散共分散行列を持つ

## ARMAモデルの選択

34

- 複数のARMA(p, q)が推定されたとき、どれを選ぶか?
- 「情報量規準 Information criterion が最小のものを選ぶ」
- 直感的な説明: 当てはまりがよくシンプルなモデルが良い
  - pやqを大きくすると...
  - いま持っているデータへの当てはまりが良くなる
  - パラメータの推定精度が下がる
- 赤池情報量規準 AIC =  $-2L(\theta) + 2k$
- ベイズ情報量規準 BIC =  $-2L(\theta) + k \ln(T)$ 
  - $L(\theta)$ : 最大対数尤度、k: パラメータ数、T: 標本数
  - 第1項が当てはまりの良さ、第2項が複雑さを表す
- 【参考】情報量規準自体もいまま数学の研究対象
- いろいろ試しても当てはまりが悪いときは、定常性を疑うなど、より原点に立ち返る必要がある



- (例)時刻までの結果から、時刻 $t+1$ 以降の値を予測したい
- 予測誤差:  $e_{t+1} = (y_{t+1} \text{ 観測値}) - (y_{t+1} \text{ 予測値})$
- $AP(1): y_{t+1} = c + \phi_1 y_t + \varepsilon_{t+1}$  予測値  $\rightarrow y_{t+1}$  は  $\varepsilon_{t+1}$  に依存する  $\rightarrow \varepsilon_{t+1}$  も分布.

- 平均2乗誤差 Mean Squared Error

- いま持っている情報から  $y_{t+1}$  の分布を得る
- 書き方:  $y_{t+1}|t: t$  までの情報から得た  $t+1$  の予測値

$$MSE = E(y_{t+1} - \hat{y}_{t+1})^2 = E(e_{t+1})^2 \rightarrow \min$$

- 最適予測 optimal forecast: 平均2乗誤差が最小となる予測

## 定常AR過程の予測

37

- AR( $p$ )過程の場合

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t, \varepsilon_t \sim \text{iid}N(0, \sigma^2)$$

- 1期先予測

$$\hat{y}_{t+1|t} = c + \phi_1 y_t + \dots + \phi_p y_{t-p+1}, MSE(\hat{y}_{t+1|t}) = E(\varepsilon_{t+1}^2) = \sigma^2$$

- この先を書くのは複雑でたいへん

- AR( $p$ )過程の最適予測の性質

- 最適予測は直近の  $p$  期の  $y$  の値にのみ依存する
- 予測期間が長くなると、
  - 最適予測における過去の観測値の影響は指数的に減衰する
- 予測期間が長くなるにつれて、
  - MSE は単調に増大する
  - 過程の分散に収束する

## 定常AR過程の予測

36

- AR(1)過程  $y_t = c + \phi_1 y_{t-1} + \varepsilon_t, \varepsilon_t \sim \text{iid}N(0, \sigma^2)$  の場合

- 1期先最適予測

$$\hat{y}_{t+1|t} = c + \phi_1 y_t + \varepsilon_{t+1}$$

$$\hat{y}_{t+1|t} = c + \phi_1 y_t, e_{t+1} = \varepsilon_{t+1}, MSE(\hat{y}_{t+1|t}) = \sigma^2$$

- 2期先最適予測

$$\hat{y}_{t+2|t} = (1 + \phi_1) c + \phi_1^2 y_t + \varepsilon_{t+2} + \phi_1 \varepsilon_{t+1}$$

$$\hat{y}_{t+2|t} = (1 + \phi_1) c + \phi_1^2 y_t, MSE(\hat{y}_{t+2|t}) = (1 + \phi_1^2) \sigma^2$$

- $h$  期先最適予測

$$y_{t+h} = (1 + \phi_1 + \dots + \phi_1^{h-1}) c + \phi_1^h y_t + \varepsilon_{t+h} + \phi_1 \varepsilon_{t+h-1} + \dots + \phi_1^{h-1} \varepsilon_{t+1}$$

$$= \frac{1 - \phi_1^h}{1 - \phi_1} c + \phi_1^h y_t + \underbrace{\sum_{k=0}^{h-1} \phi_1^k \varepsilon_{t+k+1}}_{MSE}$$

## 反転可能MA過程の予測

38

- 無限個の  $y$  の観測値が利用可能だと考える

$$\rightarrow \text{AR}(\infty) \text{として } y_t = \sum_{k=1}^{\infty} \eta_k y_{t-k} + \varepsilon_t \text{ と書ける}$$

$$\rightarrow \varepsilon_t \text{ の値は}$$

$$\varepsilon_t = y_t - \sum_{k=1}^{\infty} \eta_k y_{t-k} \text{ として求まる}$$

- MA(2)過程  $y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}, \varepsilon_t \sim \text{iid}N(0, \sigma^2)$  の場合

- 1期先最適予測

$$\hat{y}_{t+1|t} = \mu + \varepsilon_{t+1} + \theta_1 \varepsilon_t + \theta_2 \varepsilon_{t-1}$$

$$\hat{y}_{t+1|t} = \mu + \theta_1 \varepsilon_t + \theta_2 \varepsilon_{t-1}, MSE = \sigma^2$$

- 2期先最適予測

$$\hat{y}_{t+2|t} = \mu + \theta_2 \varepsilon_t, MSE = (1 + \theta_1^2) \sigma^2$$



- 3期先最適予測

1.9

- $h(>3)$ 期先最適予測

$$\hat{y}_{h+h} = \mu, \quad \text{MSE} = (1 + b_1^2 + b_2^2)\sigma^2 = 5\sigma^2$$

先が小さくなる...

- 反転可能なMA( $q$ )過程の最適予測の性質
  - $q$ 期までの最適予測はすべての観測値に依存する
  - $q+1$ 期以降の最適予測は過程の期待値と等しい
  - $q$ 期までのMSEは予測期間が長くなるにつれて単調に増加
  - $q+1$ 期以降のMSEは過程の分散と等しい

## (定常)ARMA過程の予測

41

- たとえば、有限個の $y$ 、ARMA(1,1)、 $\varepsilon_0 = \varepsilon_1 = 0$ とすると、  

$$y_t = c + \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}, \quad \varepsilon_t \sim \text{iid} N(0, \sigma^2)$$
- ここで、  

$$\varepsilon_t = y_t - c - \phi_1 y_{t-1} - \theta_1 \varepsilon_{t-1}$$
- だから、  

$$\hat{\varepsilon}_2 = y_2 - c - \phi_1 y_1$$

$$\hat{\varepsilon}_3 = y_3 - c - \phi_1 y_2 - \theta_1 \hat{\varepsilon}_2$$

$$\hat{\varepsilon}_4 = y_4 - c - \phi_1 y_3 - \theta_1 \hat{\varepsilon}_3$$
- これを使うと、最適予測

$$\hat{y}_{t+h} = c + \phi_1 y_t + \theta_1 \hat{\varepsilon}_t$$

$$\text{MSE}(\hat{y}_{t+h}) \rightarrow \sigma^2$$

## 反転可能MA過程の予測

- 有限個の $y$ しか観測できない場合はどうするか？
- $q+1$ 期以降の予測は  $\hat{y}_{t+q+1|t} = \mu$ ,  $\text{MSE}(\hat{y}_{t+q+1|t}) = \gamma_0$
- $q$ 期以前は具体的に $\varepsilon_t$ の近似値を求めていく
- たとえばMA(2)で $\varepsilon_0 = 0$ とすれば以下のような手順

$$\begin{aligned} \hat{\varepsilon}_1 &= y_1 - \mu \\ \hat{\varepsilon}_2 &= y_2 - \mu - \theta_1 \hat{\varepsilon}_1 \\ \hat{\varepsilon}_3 &= y_3 - \mu - \theta_1 \hat{\varepsilon}_2 - \theta_2 \hat{\varepsilon}_1 \\ &\vdots \end{aligned}$$

## 【参考】応用・発展的な事項

42

- 枠組みの拡張
  - 平均や分散が時間変化する場合
  - 被説明変数が2変数以上の場合(ベクトル自己回帰)
  - 季節変動などが含まれる場合
  - 観測値ではなく潜在状態が時系列に従う場合(状態空間)
  - 時刻が連続値をとる場合(確率微分方程式)
- 推定方法・計算方法
  - 逐次推定・ベイズ推定
  - モンテカルロシミュレーション
- 応用分野
  - モデル特定
  - モデルスライッシング
  - データマイニング・異常検出